

Universidade Nova de Lisboa
NOVA IMS Information Management School



TÉCNICAS DE MACHINE LEARNING EM CONTEXTO GEOESPACIAL

Trabalho de Data mining
Professor Doutor: Fernando Lucas Bação

Pós-Graduação em Ciência dos Dados Geoespaciais

Aluna: Rita Seixas
Email: 20231417@novaims.unl.pt
Ano Letivo: 2023/2024

Índice geral

Índice geral	2
Índice de figuras.....	3
Introdução.....	4
Objetivos.....	5
Package 1 – Modelos não supervisionados.....	6
1. Classificação Geodemográfica	6
2. Classificação Imagens de Satélite	12
Package 2 – Modelos supervisionados.....	15
3. Modelação Preditiva: Estações Meteorológicas.....	15
4. Modelação Preditiva: Novo Medicamento.....	17
Objetivo 1: Prever qual o melhor fármaco para um dado paciente através de uma rede neuronal.....	18
Objetivo 2 - Obter estimativas sobre a taxa de erro da rede neuronal.....	19
Objetivo 3 - Prever o melhor fármaco para os 20 pacientes do ficheiro "Farmacias_desconhecidos.xlsx"	20
Anexos.....	22
Decision tree learner	22

Índice de figuras

Figura 1. Exercícios propostos no Project Pack.....	4
Figura 2. Distribuição espacial dos habitantes mais velhos (acima de 65 anos)	6
Figura 3. Variáveis Seleccionadas.....	7
Figura 4. Workflow Knime para a realização da classificação geodemográfica	7
Figura 5. Variáveis Seleccionadas.....	8
Figura 6. Variáveis Seleccionadas.....	9
Figura 7. Variáveis Seleccionadas.....	9
Figura 8. Variáveis Seleccionadas.....	10
Figura 9. Distribuição demográfica da cidade de Lisboa com base nos clusters identificados. ...	11
Figura 10. Fluxo de trabalho no knime para análise de clusterização k-means do uso do solo com agrupamentos de K=3 (fluxo de cima) e K=7 (fluxo de baixo)	12
Figura 11. Método k-Means para K=3.....	13
Figura 12. Método k-Means para K=7.....	13
Figura 13. Gráficos de “Parallel Coordinate Plot” demonstrando a clusterização k-means quando K=3 (esquerda) e K=7 (direita).....	13
Figura 14. Fluxo de trabalho no KNIME para análise da precisão na previsão de temperatura das estações meteorológicas usando redes neurais Multilayer Perceptron (MLP).....	15
Figura 15. Comparação de métricas de desempenho para previsões de temperatura nas estações E1, E2, E3 e E4, destacando a precisão das previsões e suportando a decisão de encerramento da estação E2 com base no menor erro quadrado médio observado.....	16
Figura 16. Fluxo de trabalho do modelo de rede neuronal Multilayer Perceptron (MLP) no knime para previsão de dados	17
Figura 17. Matriz de confusão para as previsões do modelo de rede Multilayer Perceptron (MLP) perceptron sobre a eficiência de fármacos	18
Figura 18. Resumo das métricas de desempenho do modelo da rede neuronal Multilayer Perceptron (MLP).....	19
Figura 19. Previsões de fármacos para pacientes desconhecidos baseados na rede neuronal “Multilayer perceptron” (MLP) e no modelo “Decision tree predictor”	20
Figura 20. Fluxo de trabalho do modelo de rede neuronal Multilayer Perceptron (MLP) no knime para previsão de dados	22
Figura 21. Análise do modelo de treino baseado em árvores de decisão	22
Figura 22. Matriz de confusão para as previsões do modelo de rede Multilayer Perceptron (MLP) perceptron sobre a eficiência de fármacos	22
Figura 23. Resumo das métricas de desempenho do modelo da rede neuronal Multilayer Perceptron (MLP).....	23

Introdução

Este relatório sintetiza a resolução dos exercícios propostos no Project Pack, que constitui o trabalho final da Unidade Curricular de Data Mining Geoespacial. O trabalho foi estruturado em 4 tarefas principais, seguindo a sequência apresentada no tutorial fornecido, (figura 1). As tarefas dividem-se entre modelos de aprendizagem não-supervisionadas (clustering) e supervisionadas (previsão), explorando técnicas e ferramentas variadas como o KNIME Analytics, Excel, e ArcGIS Pro.



Figura 1. Exercícios propostos no Project Pack.

No âmbito dos modelos **não-supervisionados**, aplicou-se o *clustering*, que incluiu técnicas como *K-means*, para segmentar dados em grupos baseados nas suas semelhanças, sem utilizar rótulos predefinidos.

Os modelos **supervisionados**, como as Redes neuronais artificiais e as Árvores de decisão, são aplicados para prever e classificar novos dados, com base na aprendizagem de padrões identificados nos dados de treino.

Este relatório, portanto, não detalha apenas o processo e os resultados obtidos de cada modelo aplicado, mas também valida a eficácia das diferentes técnicas de *machine learning* em contextos geoespaciais, assegurando uma compreensão robusta nos seus mecanismos e aplicabilidades.

Objetivos

Package 1 – Modelos não supervisionados

1. Classificação Geodemográfica

Analisar o desenvolvimento de uma classificação geodemográfica para a cidade de Lisboa. Cujo objetivo consiste em ajudar a compreender os aspetos básicos do desenvolvimento de classificações geodemográficas, que podem ser encaradas como um caso particular de uma tarefa de clustering e segmentação

2. Classificação Imagens de Satélite

Modelação preditiva com recurso a imagem de satélite para elaboração de uma rede neuronal composta por três classes diferentes de uso do solo (urbano, rural e floresta) com recurso a um algoritmo de clustering de modos a classificar estes dados de acordo com as três classes a que pertencem

Package 2 – Modelos supervisionados

3. Modelação Preditiva: Estações Meteorológicas

Criação de uma rede neuronal composta por três classes diferentes de uso do solo (1=urbano, 2=rural e 3=floresta).

4. Modelação Preditiva: Novo Medicamento

Desenvolver um sistema preditivo que permita dar respostas sobre um novo fármaco e em que pacientes é mais adequado o uso.

Package 1 – Modelos não supervisionados

1. Classificação Geodemográfica

Definição do problema

Esta tarefa consiste em desenvolver uma classificação geodemográfica para a cidade de Lisboa e demonstrar que é possível analisar os valores médios de cada cluster, de maneira a agrupar-se características comuns em diferentes zonas da cidade de Lisboa.

De maneira a conhecer-se os dados e perceber-se o que significam e como funcionam, elaborou-se um mapa que mostra a distribuição espacial da população residente mais idosa (acima de 65 anos). Neste mapa é possível observar-se que existe um ligeiro padrão da população mais envelhecida que se distribuiu mais no centro da cidade, enquanto nas áreas mais afastadas do centro, não se verifica tanta população idosa.

Distribuição espacial dos habitantes mais velhos (acima dos 65 anos)




Figura 2. Distribuição espacial dos habitantes mais velhos (acima de 65 anos)

Seleção das variáveis para a classificação demográfica

Depois de se observar e conhecer os dados, selecionaram-se 16 variáveis, na qual foram divididas por idade, educação e ocupação, família e alojamento que estão representadas na figura 3.

Idade	
HR65	Homens residentes com 65 ou mais anos
MR65	Mulheres residentes com 65 ou mais anos
HR65+MR65	Total de homens e mulheres com 65 ou mais anos
Educação	
IRQA_001	Indivíduos residentes sem saber ler nem escrever
IRQA_110+120+130	Indivíduos residentes com o ensino básico completo
IRQA_200	Indivíduos residentes com o ensino secundário completo
IRQA_300	Indivíduos residentes com um curso médio completo
IRQA_400	Indivíduos residentes com um curso superior completo
Ocupação	
IR_PR	Indivíduos residentes pensionistas ou reformados
IR_EP	Indivíduos residentes empregados
Família	
TTFc	Total de famílias clássicas
FCR1_2	Famílias clássicas com 1 ou 2 pessoas
FCR3_4	Famílias clássicas com 3 ou 4 pessoas
FCPMA65	Famílias clássicas com pessoas com 65 ou mais anos
Alojamento	
AFCRH1_2D	Alojamentos clássicos de residência habitual com 1 ou 2 divisões
AFCRH3_4D	Alojamentos clássicos de residência habitual com 3 ou 4 divisões
AFCRHPO	Alojamentos clássicos de residência habitual com proprietário ocupante
AFCRHARR	Alojamentos clássicos de residência habitual arrendados

Figura 3. Variáveis Seleccionadas

Procedimento

O procedimento seguido para realizar a classificação geodemográfica apresenta-se esquematizado no workflow construído no Knime, apresentado na figura 4, sendo descritos nos pontos seguintes os passos relevantes.




Figura 4. Workflow Knime para a realização da classificação geodemográfica

Analise de Outliers

Durante a análise de dados, identificaram-se outliers devido à sensibilidade de certos métodos de análise de clusters a essas anomalias, que podem distorcer os resultados. Valores significativamente distintos da média podem resultar em clusters atípicos. Assim, todos os outliers identificados na Figura 5 foram substituídos pelos valores mais próximos.

Durante a análise, identificaram-se outliers negativos cuja origem não é clara, e possíveis causas incluem métodos de normalização como Z-score ou erros de cálculo. No entanto, como esses valores foram substituídos pelos valores mais próximos, não impactou a análise, permitindo que o processo prosseguisse adequadamente.

Rows: 16 | Columns: 5

☐	#	RowID	Outlier column String	Member count Number (integer)	Outlier count Number (integer)	Lower bound Number (double)	Upper bound Number (double)
☐	1	Row0	Alojamentos clássicos de residência habitual com 1 ou 2 divisões	884	36	-28	76
☐	2	Row1	Alojamentos clássicos de residência habitual com 3 ou 4 divisões	884	14	-47	273
☐	3	Row2	Alojamentos clássicos de residência habitual arrendados	884	17	-62.5	293.5
☐	4	Row3	Alojamentos clássicos de residência habitual com proprietário ocupante	884	13	-81.5	314.5
☐	5	Row4	Total de famílias clássicas	884	52	102	422
☐	6	Row5	Famílias clássicas com pessoas com 65 ou mais anos	884	32	8	208
☐	7	Row6	Famílias clássicas com 1 ou 2 pessoas	884	30	30	294
☐	8	Row7	Famílias clássicas com 3 ou 4 pessoas	884	31	-6	170
☐	9	Row8	Homens residentes com 65 ou mais anos	884	31	-3.5	112.5
☐	10	Row9	Mulheres residentes com 65 ou mais anos	884	22	-2	190
☐	11	Row...	Indivíduos residentes empregados	884	38	24	528
☐	12	Row...	Indivíduos residentes pensionistas ou reformados	884	42	14.5	306.5
☐	13	Row...	Indivíduos residentes sem saber ler nem escrever	884	78	-15	129
☐	14	Row...	Indivíduos residentes com o ensino secundário completo	884	17	-17.5	218.5
☐	15	Row...	Indivíduos residentes com um curso médio completo	884	11	-12.5	31.5
☐	16	Row...	Indivíduos residentes com um curso superior completo	884	33	-124	316

Figura 5. Variáveis Seleccionadas

Normalização dos dados

Segundo o enunciado todos os dados já tinham sido normalizados, como tal, após a importação dos dados para o Knime não se procedeu a mais nenhuma normalização.

Classificação GeoDemográfica

Para otimizar as variáveis de input e escolher as finais para a segmentação, realizou-se uma análise de correlações. Utilizando o node “Linear Correlation”, construíram-se matrizes de correlação entre as variáveis de temas como Idade, Alojamento, Família, Ocupação e Educação, para identificar as suas relações.

Posteriormente, com o node “Correlation Filter”, seleccionaram-se as variáveis finais de input, estabelecendo-se um limite máximo de correlação de 0.5. Esta metodologia resultou na seleção das variáveis finais de input representadas na figura 6:

Idade	
HR65	Homens residentes com 65 ou mais anos
MR65	Mulheres residentes com 65 ou mais anos
HR65+MR65	Total de homens e mulheres com 65 ou mais anos
Educação	
IRQA_001	Indivíduos residentes sem saber ler nem escrever
IRQA_110+120+130	Indivíduos residentes com o ensino básico completo
IRQA_200	Indivíduos residentes com o ensino secundário completo
Ocupação	
IR_PR	Indivíduos residentes pensionistas ou reformados
Família	
FCR1_2	Famílias clássicas com 1 ou 2 pessoas
FCPMA65	Famílias clássicas com pessoas com 65 ou mais anos
Alojamento	
AFCRH1_2D	Alojamentos clássicos de residência habitual com 1 ou 2 divisões
AFCRHARR	Alojamentos clássicos de residência habitual arrendados

Figura 6. Variáveis Seleccionadas

Clusters “profiling”

Com base nos resultados obtidos a partir da aplicação do método K-means, foram calculadas as médias Intra cluster de cada variável (figura 7), que foram colocadas num gráfico radar (figura 8), no sentido de interpretar o significado de cada um dos clusters identificados.

Variável	cluster_1	cluster_2	cluster_3
Indivíduos residentes empregados	394	265	246
Indivíduos residentes pensionistas ou reformados	218	178	89
Indivíduos residentes sem saber ler nem escrever	133	53	50
Indivíduos residentes com o ensino básico completo	509	274	176
Indivíduos residentes com o ensino secundário completo	110	108	90
Indivíduos residentes com um curso médio completo	8	12	9
Indivíduos residentes com um curso superior completo	68	113	135
Homens residentes com 65 ou mais anos	72	63	32
Mulheres residentes com 65 ou mais anos	114	109	53
Total residentes com 65 ou mais anos	185	172	85
Total de famílias clássicas	333	271	199
Famílias clássicas com pessoas com 65 ou mais anos	131	123	62
Famílias clássicas com 1 ou 2 pessoas	175	183	116
Famílias clássicas com 3 ou 4 pessoas	126	77	73
Alojamentos clássicos de residência habitual com 1 ou 2 divisões	32	31	17
Alojamentos clássicos de residência habitual com 3 ou 4 divisões	173	116	75
Alojamentos clássicos de residência habitual arrendados	182	127	61
Alojamentos clássicos de residência habitual com proprietário ocupante	125	119	121

Figura 7. Variáveis Seleccionadas




Figura 8. Gráfico radar com os clusters "profiling"

Classificação GeoDemográfica

O gráfico radar fornece uma visão detalhada das preferências habitacionais e educacionais dos três clusters distintos, enfocando uma população idosa em situação de reforma ou pensionista. De uma forma geral considera-se que os resultados apresentam semelhanças significativas, tornando-se difícil realizar uma análise mais detalhada e concreta.

- **Cluster 1 (Azul):** Este cluster tem uma forte presença de "Alojamentos clássicos de residência habitual arrendados" e um nível educacional básico predominante. Este perfil sugere uma população idosa que valoriza a flexibilidade e a conveniência dos arrendamentos em áreas urbanas, possivelmente devido a um estilo de vida mais dinâmico ou a restrições financeiras que desencorajam o compromisso de longo prazo com propriedades próprias.

- **Cluster 2 (amarelo):** Caracteriza-se por uma preferência por "Alojamentos clássicos de residência habitual com 1 ou 2 divisões", indicando que indivíduos ou casais idosos que favorecem espaços menores. A composição deste cluster pode querer refletir alguma estabilidade e conforto na propriedade de longo prazo, sugerindo que esses idosos têm condições financeiras ou pessoais que suportam a manutenção de um lar próprio.

- **Cluster 3 (vermelho):** Este cluster exibe uma maior diversidade educacional, variando do ensino básico ao secundário completo, com uma variedade menos definida de preferências habitacionais. Isso indica uma população idosa mais heterogênea, e pode incluir indivíduos que mantêm uma vida mais ativa e social.

Resultados

O mapa da cidade de Lisboa, com as secções estatísticas classificadas pelos clusters identificados (figura) mostra que:

Nas zonas contíguas ao centro da cidade (ex: Beato, Marvila, parque das nações) e algumas zonas periféricas (Ex: santa clara e ajuda), encontram-se os residentes com ensino básico, que habitam em alojamentos arrendados (**Cluster 1**).

Os residentes maioritariamente com 65 anos ou mais, com aglomerado familiar com 1 ou 2 pessoas, reformados ou pensionistas (**Cluster 2**), habitam principalmente no centro da cidade, nas zonas mais antigas, com algumas extensões a bairros mais periféricos, como por exemplo, Olivais. Esta população contém o maior grupo de residentes com 65 anos ou mais.

Os residentes com maior diversidade educacional e uma variedade menos definida de preferências habitacionais (**Cluster 3**), habitam principalmente em zonas mais periféricas, como Carnide, Benfica ou Lumiar.

Distribuição espacial dos Clusters




Figura 9. Distribuição demográfica da cidade de Lisboa com base nos clusters identificados.

2. Classificação Imagens de Satélite

Definição do problema

Esta etapa consiste em detetar se as redes neuronais são bons classificadores de imagens de satélite.

Nesse sentido, aplicou-se o método de clusterização k-Means, uma técnica robusta e não supervisionada para análise de dados, a fim de classificar e segmentar imagens de satélite de uso do solo em três categorias principais de uso do solo (1=urbano, 2=rural e 3=floresta). Cada registo (pixel) nos dados analisados possui quatro atributos, referidos como bandas.

Para explorar a eficácia da clusterização em diferentes níveis de granularidade, realizar-se-á duas análises com k-Means para (k=3) e (k=7), comparando posteriormente os resultados para entender as nuances e as variações entre esses dois agrupamentos.




Figura 10. Fluxo de trabalho no knime para análise de clusterização k-means do uso do solo com agrupamentos de K=3 (fluxo de cima) e K=7 (fluxo de baixo)

Interpretação

Conforme a figura 10, o processo começa com a **leitura** dos dados de satélite e logo de seguida com a normalização dos dados das quatro bandas.

A **normalização** é um processo crucial no k-Means para determinar adequadamente o número de clusters, que redimensiona os valores originais para uma escala uniforme que varia de 0 a 1. Existem três métodos de normalização disponíveis: "minmax", "zscore" e "normalization by decimal scaling". Utilizou-se o método "min-max".

Após a normalização dos dados, eles são processados através do algoritmo **k-Means**, um método de clusterização utilizado para dividir os dados em grupos, ou clusters. Este método garante que os pontos de dados em cada grupo sejam mais similares entre si do que com os de outros grupos. Devido à exigência de exclusivamente variáveis numéricas pelo método, a variável "classe" foi excluída.




Figura 11. Método k-Means para K=3



Figura 12. Método k-Means para K=7

A fase seguinte foi a **desnormalização**, para reverter os dados para a escala original. Esse processo assegura que os parâmetros usados na normalização sejam aplicados inversamente, tornando os resultados do k-Means compreensíveis no contexto original dos dados.

Na próxima etapa, o **"Color Manager"** é utilizado para atribuir cores aos dados da variável "clusters". Posteriormente, implementa-se o **"Parallel Coordinates Plot"** para visualizar as variáveis. Neste passo, inclui-se a variável "cluster" e exclui-se a "classe", mantendo-se as variáveis das bandas.




Figura 13. Gráficos de "Parallel Coordinate Plot" demonstrando a clusterização k-means quando K=3 (esquerda) e K=7 (direita)

Utilizando o método k-Means para (K=3) e (K=7), pretende-se explorar a distribuição e diferenciação das três principais categorias de uso do solo: urbano, rural e floresta, conforme representadas pelas quatro bandas medidas em imagens de satélite.

Análise para (K=3)

No caso de (K=3), os clusters mostram distinções claras que sugerem categorizações bem definidas (figura 11). O primeiro cluster (cluster_0), apresenta valores mais baixos em Band1, Band 3 e Band4, enquanto Band2 é moderadamente alta, sugerindo uma característica possivelmente rural devido à menor reflexão em bandas que capturam infraestrutura urbana. O segundo cluster (cluster_1), tem os valores altos em praticamente todas as bandas, tipicamente refletindo áreas urbanas com alta densidade de construção. O terceiro cluster (cluster_3), com valores moderados em todas as bandas, pode representar áreas de floresta, onde a reflexão é equilibrada em todas as medidas espectrais.

Análise para (K=7)

Com (K=7), os dados mostram uma diferenciação mais detalhada, no entanto, observam-se também algumas redundâncias (figura 12). Como os clusters 0, 4 e 3 possuem perfis espectrais semelhantes, levanta a questão sobre a necessidade de utilizar um número tão alto de clusters. Isso indica que a separação adicional pode estar a capturar variações mínimas que não são necessárias na classificação de uso do solo.

Comparação e Interpretação dos Gráficos de Coordenadas Paralelas

A comparação entre (K=3) e (K=7) sugere que um menor número de clusters é mais eficaz para segmentar claramente as categorias de uso do solo desejadas ((figura 13). Enquanto (K=3) oferece uma clara distinção que mapeia de forma eficaz as três classes definidas, (K=7) parece introduzir complexidade sem benefícios analíticos adicionais significativos, o que nos permite afirmar que, é mais vantajoso optar por menos clusters do que ter maior variabilidade.

Package 2 – Modelos supervisionados

3. Modelação Preditiva: Estações Meteorológicas

Definição do problema

No contexto de restrições orçamentais, foi realizada uma análise para determinar a viabilidade de manter todas as quatro estações meteorológicas ao longo da costa portuguesa. Utilizando técnicas de machine learning, especificamente redes neurais do tipo Multilayer Perceptron (MLP), avaliou-se a capacidade de prever a temperatura numa estação com base nas medições das outras três. Esta análise foi crucial para identificar qual estação que poderia ser encerrada com o menor impacto na precisão global das previsões meteorológicas.

Através do software KNIME, os dados das temperaturas das quatro estações meteorológicas foram recolhidos e processados, seguindo-se o fluxo de trabalho (figura 14):




Figura 14. Fluxo de trabalho no KNIME para análise da precisão na previsão de temperatura das estações meteorológicas usando redes neurais Multilayer Perceptron (MLP).

Interpretação

Os dados foram carregados, lidos e **normalizados** para garantir uniformidade entre escalas de medição, evitando assim qualquer enviesamento no modelo.

Com o nó "**Partitioning**", os dados foram divididos, atribuindo 70% para treino e 30% para validação. Esta estratificação garantiu que cada segmento mantivesse a representatividade das condições climáticas observadas no conjunto de dados total.

Quatro nós "**RProp MLP Learner**" foram configurados para implementar um esquema de validação cruzada, onde cada um exclui os dados de uma estação climática específica, usando as outras três para treinar os modelos destinados a prever temperaturas.

Cada modelo treinado pelo "RProp MLP Learner" foi então aplicado no nó "**Multilayer Perceptron Predictor**", que utiliza as funções aprendidas para estimar as temperaturas nas estações excluídas, permitindo uma avaliação robusta da performance preditiva dos modelos.

Por fim, cada modelo foi avaliado usando o nó "**Numeric Scorer**", focando-se na métrica do erro médio quadrático (MSE - mean squared error).

Resultados

A estação a encerrar deverá ser a E2.

De acordo com a figura 15, a análise do erro médio quadrado (MSE) revelou que as previsões para E2, quando omitida, apresentaram o menor erro em comparação com as outras estações, indicando que as três estações restantes podem prever de forma eficaz e com alta precisão a temperatura que seria medida por E2.

Por outras palavras, a similaridade nas medições entre as estações, indica que a ausência de uma delas permitirá uma redução de custos, mantendo a integridade e a precisão da rede meteorológica.

	Prediction (E1)	Prediction (E2)	Prediction (E3)	Prediction (E4)
R ²	0,972992332	0,983881563	0,963269261	0,978449351
mean absolute error	0,038963459	0,025290041	0,037413669	0,028857556
mean squared error	0,002187078	0,001034144	0,002068139	0,001391027
root mean squared error	0,046766203	0,032158102	0,0454768	0,037296473
mean signed difference	-0,004969646	-0,002979583	0,004104387	-0,001310585
mean absolute percentage error	#NUM!	0,11619663	0,194269583	0,113256393
adjusted R ²	0,972992332	0,983881563	0,963269261	0,978449351

Figura 15. Comparação de métricas de desempenho para previsões de temperatura nas estações E1, E2, E3 e E4, destacando a precisão das previsões e suportando a decisão de encerramento da estação E2 com base no menor erro quadrado médio observado.

4. Modelação Preditiva: Novo Medicamento

Definição do problema

Para abordar os desafios no tratamento de patologias do sistema circulatório, a empresa desenvolveu um sistema preditivo utilizando técnicas avançadas de Data Mining. O sistema visa identificar o fármaco mais adequado entre cinco opções disponíveis: drugA, drugB, drugC, drugX, e drugY.

Seguem-se os objetivos deste exercício, que serão respondidos mais à frente:

1. Prever o fármaco mais adequado para um dado paciente utilizando a rede neural;
2. Estimar a taxa de erro esperada do modelo para avaliar sua precisão;
3. Aplicar o modelo para prever o fármaco adequado para os 20 pacientes cujos dados são desconhecidos.

Para facilitar a análise foi concebido um fluxo de trabalho utilizando o software KNIME para implementar uma rede neural do tipo Multilayer Perceptron (MLP). Seguem-se os passos detalhados (figura 16):




Figura 16. Fluxo de trabalho do modelo de rede neural Multilayer Perceptron (MLP) no knime para previsão de dados

Interpretação

Utilizou-se o "Excel Reader" para carregar os dados de duas tabelas: uma com informações de 500 pacientes (dados realísticos) e outra com dados de pacientes desconhecidos.

Começou por se fazer um "**Column Filter**" para excluir variáveis nominais, dado que não são compatíveis com o treino de redes neurais. Em seguida, as variáveis numéricas foram normalizadas usando o método Min-Max para garantir uma escala uniforme e minimizar a influência de valores discrepantes.

Posteriormente os dados foram estratificados usando o "**Partitioning**", dividindo-os em 70% para treino e 30% para validação. Esta abordagem assegura que a variável de resposta, ou seja, a eficácia do fármaco, seja representada proporcionalmente em ambos os conjuntos.

Em seguida o modelo foi treinado com o "**RProp MLP Learner**", ajustando os parâmetros para otimizar a convergência e minimizar o erro.

Após o treino, o modelo foi aplicado usando o "**Multilayer Perceptron Predictor**", que utilizou as funções aprendidas para estimar a eficácia do fármaco em pacientes não incluídos no conjunto de treino, validando assim a precisão e a aplicabilidade do modelo desenvolvido.

Objetivo 1: Prever qual o melhor fármaco para um dado paciente através de uma rede neuronal

Drug \ Pre...	drugA	drugY	drugX	drugB	drugC
drugA	8	1	10	0	0
drugY	0	68	0	0	0
drugX	6	1	26	2	0
drugB	0	0	11	0	0
drugC	8	2	8	0	0

Figura 17. Matriz de confusão para as previsões do modelo de rede Multilayer Perceptron (MLP) perceptron sobre a eficiência de fármacos

A matriz de confusão é uma ferramenta fundamental para determinar o desempenho do modelo de classificação, e definir qual o melhor fármaco para um dado paciente com base nos dados de validação.

Análise

Conforme a figura 17, os valores da diagonal estão bem classificados, tudo o que está fora dela são erros de classificação.

O modelo teve um bom desempenho com o fármaco Y, acertando 68 de 68 vezes, ou seja, houve 68 casos em que a droga Y foi prevista e acertada corretamente.

Para o fármaco X, houve 26 previsões corretas, e 6 vezes em que o modelo confundiu X com A, 1 com Y, e 2 com B.

Os fármacos A e C mostraram um alto número de confusões com outros fármacos, o que indica uma área de preocupação para a precisão do modelo em relação a esses fármacos.

Conclusões

O modelo é eficaz na previsão do fármaco Y, que parece ser o mais fácil de prever corretamente. A previsão para os fármacos A, X, e C precisa de melhorias, pois o modelo confunde frequentemente esses fármacos com outros.

Pode ser necessário rever os parâmetros do modelo, considerar mais dados ou até mesmo rever como as variáveis estão a ser utilizadas pelo modelo.

Objetivo 2 - Obter estimativas sobre a taxa de erro da rede neuronal

Correct classified: 102	Wrong classified: 49
Accuracy: 67,55%	Error: 32,45%
Cohen's kappa (κ): 0,524%	

Figura 18. Resumo das métricas de desempenho do modelo da rede neuronal Multilayer Perceptron (MLP)

Análise

De acordo com a figura 18, dos 151 casos avaliados (soma dos corretos e errados), 102 foram corretamente classificados pelo modelo. Isso representa uma **precisão** geral de 68%. Este valor indica que, em média, o modelo é capaz de prever corretamente o melhor fármaco para aproximadamente dois terços dos pacientes na amostra de validação.

O modelo errou em 49 dos 151 casos, resultando numa **taxa de erro** de 32%. Esta taxa de erro revela a frequência com que o modelo falha ao tentar prever o fármaco correto.

O valor de **Cohen's Kappa** de 0,524% é um indicativo da concordância entre as previsões do modelo e as classificações verdadeiras, ajustado pela concordância que poderia ser esperada ao acaso. Um valor acima de 0,5 é geralmente visto como uma indicação de boa concordância, considerando que valores de Kappa podem variar de -1 (concordância total negativa) a +1 (concordância total positiva).

Conclusões

A precisão de cerca de 68% e o Cohen's Kappa indicam que o modelo é razoavelmente confiável, mas pode necessitar de melhorias para aumentar a precisão em contextos clínicos onde escolhas incorretas de fármacos têm consequências graves. Esta necessidade de precisão torna-se ainda mais crítica ao considerar os riscos associados aos falsos positivos e negativos: enquanto um falso positivo pode causar um alarme desnecessário, um falso negativo, classifica erroneamente pessoas doentes como saudáveis, que pode ter consequências devastadoras, enfatizando a importância de refinar ainda mais o modelo para minimizar tais erros.

Objetivo 3 - Prever o melhor fármaco para os 20 pacientes do ficheiro "Farmacias_desconhecidos.xlsx"

age	Sex	c1	c2	c3	c4	MLP predictor	Decision tree predictor
34	F	HIGH	HIGH	0,864092	0,067528	drugY	drugA
55	F	HIGH	NORMAL	0,821441	0,047962	drugY	drugY
46	M	HIGH	NORMAL	0,868366	0,05618	drugY	drugA
70	M	LOW	NORMAL	0,789451	0,028714	drugB	drugY
69	F	HIGH	HIGH	0,585406	0,026672	drugC	drugY
60	F	NORMAL	NORMAL	0,834857	0,033629	drugY	drugY
58	M	NORMAL	HIGH	0,543761	0,074563	drugB	drugX
63	F	NORMAL	NORMAL	0,641137	0,024593	drugB	drugY
52	M	HIGH	NORMAL	0,518609	0,026845	drugY	drugY
58	F	HIGH	HIGH	0,678409	0,028628	drugY	drugY
39	M	HIGH	HIGH	0,516186	0,050484	drugY	drugA
43	F	NORMAL	HIGH	0,537262	0,028071	drugY	drugY
52	F	HIGH	HIGH	0,880082	0,032083	drugY	drugY
45	M	LOW	NORMAL	0,737074	0,067265	drugY	drugX
28	M	LOW	HIGH	0,539684	0,075756	drugY	drugC
60	M	HIGH	HIGH	0,647718	0,056558	drugB	drugB
32	F	NORMAL	NORMAL	0,539994	0,05488	drugY	drugX
26	F	HIGH	HIGH	0,796647	0,036299	drugY	drugY
35	F	LOW	NORMAL	0,559568	0,076713	drugY	drugX
27	M	HIGH	HIGH	0,555917	0,062908	drugY	drugA

Figura 19. Previsões de fármacos para pacientes desconhecidos baseados na rede neuronal "Multilayer perceptron" (MLP) e no modelo "Decision tree predictor"

As previsões do fármaco mais adequado para os 20 pacientes do ficheiro com os pacientes desconhecidos, foram baseadas na rede neuronal "Multilayer Perceptron" (MLP) e no modelo "Decision Tree Predictor". A análise comparativa entre o "Multilayer Perceptron" (MLP) e o "Decision Tree Predictor" na tabela apresentada revelam diferenças significativas no desempenho desses modelos de machine learning, cada um adaptado a características distintas dos dados.

A **Decision Tree**, que utiliza seis variáveis, demonstrou uma performance superior, com uma precisão geral de 82% e um índice Cohen's Kappa de 0,746, refletindo uma alta consistência e menor taxa de erro de apenas 18% (conforme figuras 20, 21, 22 e 23 em anexo). Este resultado pode ser atribuído à sua capacidade de usar uma maior diversidade de variáveis, incluindo nominais, o que enriquece sua análise ao captar mais nuances dos dados.

Por outro lado, o **MLP**, apesar de ser uma técnica poderosa para capturar interações complexas entre variáveis, foi limitado neste caso ao usar apenas três variáveis numéricas, excluindo as nominais devido às suas limitações de input. Isso resultou numa precisão geral de 68%, com uma taxa de erro de 32% e um Cohen's Kappa de 0,524. Este resultado sugere que, embora os MLPs sejam eficazes em muitos cenários, a falta de variáveis relevantes pode comprometer significativamente sua eficácia.

Esta comparação enfatiza a importância de escolher o modelo apropriado com base nas características específicas dos dados e do problema. Enquanto o "Decision Tree Predictor" oferece

uma abordagem mais flexível e direta, adaptando-se bem a dados com variáveis nominais e proporcionando uma interpretação transparente dos resultados, o MLP requer uma seleção cuidadosa das variáveis para maximizar seu potencial. A seleção do modelo, portanto, deve considerar tanto a natureza dos dados quanto o objetivo específico da análise.

Anexos

Decision tree learner




Figura 20. Fluxo de trabalho do modelo de “Decision tree learner” no knime para previsão de dados




Figura 21. Análise do modelo de treino baseado em árvores de decisão

Drug \ Pre...	drugA	drugY	drugC	drugX	drugB
drugA	17	0	1	1	0
drugY	6	56	3	1	0
drugC	1	7	5	1	0
drugX	0	1	1	40	0
drugB	3	0	1	0	6

Figura 22. Matriz de confusão para as previsões do modelo de “Decision tree learner”

Correct classified: 124	Wrong classified: 27
Accuracy: 82,119%	Error: 17,881%
Cohen's kappa (κ): 0,746%	

Figura 23. Resumo das métricas de desempenho do modelo de "Decision tree learner"