

Avaliação de classificadores de imagens de satélite para deteção de zonas ardidas: caso do incêndio de 17 a 24 de junho de 2017, na zona do Pinhal Interior, em Portugal

Alyne Spencer Gonçalves¹, Rita Seixas² & Sílvia Pinto³

Universidade Nova de Lisboa, Information Management School

1 20230913@novaims.unl.pt

2 20231417@novaims.unl.pt

3 20230912@novaims.unl.pt

Resumo

Em 2017, Portugal enfrentou uma série de incêndios devastadores que consumiram aproximadamente 500.000 hectares de vegetação. Estes eventos trágicos ocorreram em grande escala, principalmente em dois períodos distintos: junho e outubro.

Diante deste cenário, o objetivo é comparar o desempenho entre o classificador supervisionado de máxima verosimilhança e o classificador não supervisionado Isodata Clustering, na identificação de áreas queimadas no primeiro grande incêndio, na região do Pinhal Interior, em Portugal.

As principais conclusões que se obteve com este trabalho destacam que a vantagem do método não supervisionado reside na ausência da necessidade de criar um conjunto de dados de treino, permitindo uma implementação mais rápida, algo crucial em situações de crise. Na identificação de áreas ardidas, o classificador supervisionado apresentou uma taxa de sucesso de 83%, em comparação com 70% do classificador não supervisionado. Os erros de omissão foram de 17% e 30%, respectivamente, indicando pontos de validação ardidos que não foram identificados como tal. Os erros de comissão, ou seja, pixels erroneamente classificados como ardidos, foram de 5% para o classificador supervisionado e 31% para o não supervisionado.

Palavras-chave: Deteção Remota; Incêndios; Pinhal Interior; Sentinel-2; SIG.

1 Introdução

Numa era de mudanças climáticas e crescentes riscos ambientais, torna-se imprescindível abordar o desafio dos incêndios florestais. Em 2017, Portugal foi severamente afetado por uma série de incêndios. A área ardida nesse ano foi cerca de 500 mil hectares, tendo sido designado como o pior ano de sempre na dimensão da área ardida, desde que há registos fiáveis, passando à frente do ano negro de 2003, quando arderam 430 mil hectares (Assembleia da República, 2018, p.11). Estes eventos trágicos, ocorreram em grande escala essencialmente em dois períodos distintos, em junho e de outubro de 2017. Este trabalho irá focar a sua análise no primeiro grande incêndio que atingiu a zona de Pedrógão grande, ocorrido entre 17 e 24 de junho de 2017, e que resultou em 241.000 hectares de área ardida e 64 mortes, agravado por condições climáticas extremas, como temperaturas acima dos 40°C, trovoadas secas e ventos fortes (Assembleia da República, 2018, p.18).

O estudo propõe avaliar a capacidade de classificadores de imagens de satélite em detetar e quantificar áreas afetadas por incêndios, utilizando o Pinhal Interior como área de estudo. O

objetivo é identificar qual o tipo de classificação mais adequado e que permite produzir, a curto prazo, uma cartografia das áreas ardidas que possa ser utilizada pelos municípios no planeamento de ações no terreno. Os classificadores testados neste estudo são: o classificador assistido de máxima verossimilhança, que atribui a cada pixel de uma imagem à classe com maior probabilidade de estar correta com base nas assinaturas espectrais de classes conhecidas (conjunto de treino), e o classificador não assistido Isodata Clustering, que agrupa pixels iterativamente com base em suas propriedades espectrais, sem dados de treino. Para isso, proceder-se-á à classificação de imagens de satélite com os dois métodos, e os resultados serão comparados utilizando matrizes de confusão.

2 Enquadramento da área de estudo

A área de estudo foi determinada com base nos concelhos, que foram afetados pelos incêndios ocorridos entre 17 e 24 de junho de 2017, na zona do Pinhal Interior, em Portugal.

O Pinhal Interior foi uma sub-região estatística portuguesa da NUTS III, inserida na região do Centro (Região das Beiras), subdividindo-se à época entre Pinhal Interior Norte e Pinhal Interior Sul. Esta designação esteve em vigor de 1989 a 2013, quando foi extinta, tendo posteriormente os seus concelhos sido integrados nas unidades municipais atuais de NUTS III dos Distritos de Coimbra (Região de Coimbra), Leiria (Região de Leiria) e Castelo Branco (Beira Baixa), (INE, 2015).




Figure 1. Área de Estudo

Embora o termo administrativo já não seja utilizado, ainda é reconhecido como uma área geográfica válida. Portanto, para efeitos deste trabalho, ir-se-á retratar a região como Pinhal Interior. Além disso, artigos recentes ainda utilizam este termo, o que reforça ainda mais a sua relevância na discussão sobre a área em questão.

Conforme a tabela 1, a região do Pinhal Interior é composta por 18 concelhos, dos quais 9 serão abordados na área de estudo. Ressalta-se também que o concelho de Soure abrange uma porção de território pertencente ao concelho de Ansião, o qual está fora da área de estudo.

Table 1. Concelhos do Pinhal Interior pertencentes à Área de Estudo

• Alvaiázere (Distrito de Leiria) • Ansião (Distrito de Leiria) • Castanheira de Pera (Distrito de Leiria) • Figueiró dos Vinhos (Distrito de Leiria) • Góis (Distrito de Coimbra)	• Pampilhosa da Serra (Distrito de Coimbra) • Pedrógão Grande (Distrito de Leiria) • Penela (Distrito de Coimbra) • Sertã (Distrito de Castelo Branco)
--	---

3 Metodologia e Dados

Neste estudo, adotou-se uma abordagem metodológica para investigar os efeitos dos incêndios na região do Pinhal Interior, com o objetivo principal de comparar os resultados da classificação supervisionada e não supervisionada na detecção de áreas ardidas. A metodologia empregue seguiu um esquema estruturado, conforme representado na figura 2. Para conduzir a pesquisa, foi utilizado o software ArcGIS Pro, com as coordenadas referenciadas ao sistema de coordenadas WGS 1984 UTM Zone 29N. Além disso, não foi necessária a estratificação geográfica, visto que a análise não exige a divisão da área em estratos homogêneos.

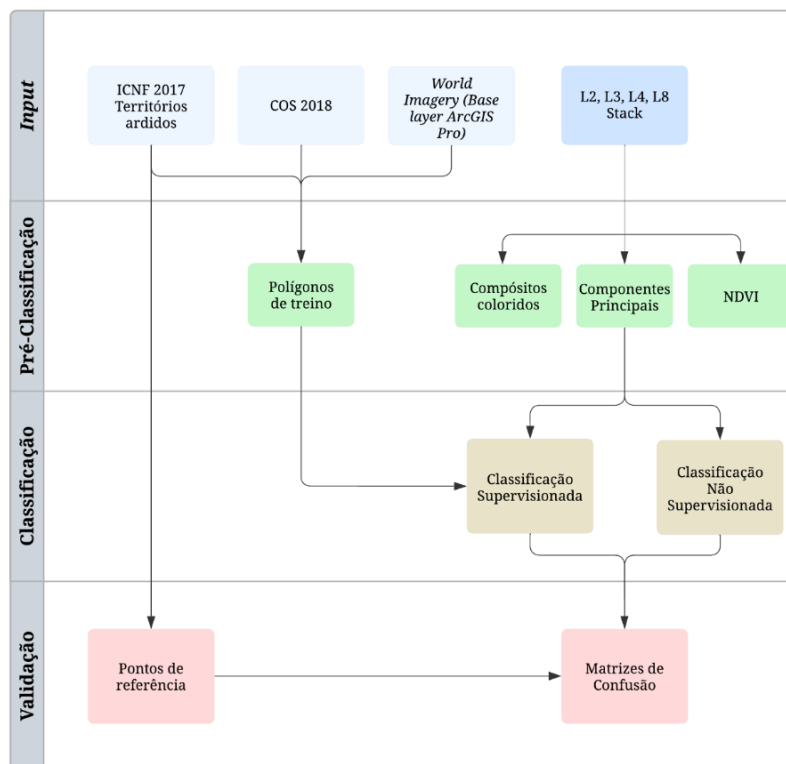


Figure 2. Esquema metodológico

3.1.1 Análise Exploratória

A análise exploratória desempenha um papel essencial na compreensão inicial e preparação dos dados para análises subsequentes. Inicialmente, realizou-se a recolha das imagens de satélite, a visualização e recolha de dados auxiliares, como a COS (carta de uso e ocupação do solo de Portugal) e, dados relativos aos territórios ardidos do Instituto da Conservação da Natureza e das Florestas (ICNF) para melhor compreensão dos territórios ardidos.

3.1.2 Seleção e Aquisição de imagens de satélite

As imagens utilizadas neste estudo foram recolhidas pelo satélite Sentinel 2 e compreendem duas datas distintas: 5 de abril de 2017 (antes do incêndio) e 24 de julho de 2017 (após o incêndio). A aquisição realizou-se através do Sentinel Hub EO Browser por ter uma resolução espacial e temporal adequada aos objetivos deste estudo. Por um lado, tem uma frequência regular de aquisição de imagens que ocorre a cada 5 dias, o que facilita encontrar imagens sem nuvens mais adaptadas à classificação.

Por outro lado, as imagens possuem uma resolução de 10 metros por pixel e são capturadas nas seguintes bandas do Sentinel-2, selecionadas especificamente para este estudo:

- Luz visível:
 - Banda 2: na faixa do azul.
 - Banda 3: na faixa do verde.
 - Banda 4: na faixa do vermelho.
- Banda 8 na faixa do infravermelho próximo.

3.1.3 Pré-processamento e Transformação de bandas

As imagens adquiridas no Sentinel Hub EO Browser já passaram pelo processo de ortorretificação, que inclui correções radiométricas e geométricas, eliminando assim a necessidade de intervenções nesse sentido. Embora as imagens sejam de distintas épocas do ano, acredita-se que essa disparidade temporal não tenha um impacto relevante em termos radiométricos.

Durante o processo de transformação de bandas, aplicaram-se diversas técnicas para a criação de composições coloridas de verdadeira e falsa cor, bem como calcular o Índice de Vegetação por Diferença Normalizada (NDVI) e os componentes principais (PC).

- **Compósitos coloridos**

No intuito de facilitar a exploração da área de estudo, utilizou-se um compósito de cor verdadeira, com as bandas 4, 3 e 2 assim como um compósito colorido de falsa cor já disponível no EO Hub que combinava as bandas do infravermelho de ondas curtas 2, do infravermelho próximo e do vermelho.

- **Índice de Vegetação por Diferença Normalizada (NDVI)**

Uma forma preliminar de avaliar as zonas ardidas foi o recurso ao cálculo do NDVI e do dNDVI (*Differenced Normalized Difference Vegetation Index*) para os meses de abril e de julho, visando a obtenção de mapas que representem a cobertura vegetal, a diferença e mudança da distribuição da mesma.

O NDVI é um índice crucial para a monitorização de mudanças sazonais na vegetação e na avaliação do impacto de eventos ambientais, como por exemplo, incêndios florestais. Este índice é calculado a partir das refletâncias nas bandas vermelha (RED) e infravermelha próxima (NIR), conforme indicado na seguinte fórmula: $NDVI = \frac{NIR - RED}{NIR + RED}$

O NDVI varia entre -1 e 1, onde os valores mais próximos de 1 indicam uma maior presença de vegetação, em contraste valores negativos ou próximos de zero sugerem áreas como edifícios, água e solos, com pouca ou nenhuma presença de vegetação (Caetano & Costa, 2023; Castro & Amaral, 2017). Com base nos resultados obtidos para os meses mencionados, procedeu-se ao cálculo do dNDVI, que consiste em calcular a diferença aritmética entre os valores de NDVI de julho e abril. Para o cálculo do dNDVI, utilizou-se a seguinte fórmula: $dNDVI = NDVI_{julho} - NDVI_{abril}$.

Para interpretar as mudanças na distribuição da cobertura vegetal ao longo do período analisado, foi aplicada uma segunda fórmula: $\mu - k\sigma < dNDVI < \mu + k\sigma$.

Onde:

- μ representa a média.
- σ representa o desvio padrão
- O parâmetro k é igual a 1, o que significa que todos os pixels cuja diferença de NDVI esteja dentro de ± 1 desvio padrão da média serão considerados como parte das mudanças significativas na distribuição da cobertura vegetal.

• Componentes Principais

Na deteção remota, a análise de componentes principais é uma técnica fundamental para reduzir a complexidade e a redundância dos dados, especialmente quando se trata de conjuntos de múltiplas bandas de imagem (Caetano & Costa, 2023). Neste projeto, optou-se por aplicar a análise de componentes principais visando destacar os padrões mais significativos presentes nas informações contidas nas bandas. Esta decisão baseou-se na compreensão de que as duas primeiras componentes principais explicam a maioria da variabilidade dos dados, tornando-as as mais relevantes para análises subsequentes. No entanto, os detalhes que influenciaram esta escolha serão abordados posteriormente.

3.1.4 Nomenclaturas

Na fase de classificação, adotaram-se tanto abordagens não supervisionadas quanto supervisionadas, consideradas ambas como técnicas proeminentes na implementação de classificadores em deteção remota. Estas abordagens visam identificar e categorizar as classes de interesse nas imagens. Com o objetivo de facilitar a classificação das classes de informação, elaborou-se uma tabela com a descrição das nomenclaturas (tabela 2). Esta tabela, serviu de referência para ambas os dois tipos de classificação, de forma a garantir consistência e precisão na análise dos dados.

Table 2. Tabela das nomenclaturas

Código	Nome	Descrição
1	Água	Massas de água superficiais
2	Agricultura	Agricultura familiar e de subsistência que pode incluir culturas diversas.
3	Florestas/matos	Vegetação fotossinteticamente ativa na Primavera e no Verão, como matagais, árvores e pastagens
4	Ardidos	Territórios ardidos no período de 17 a 24 de junho de 2017
5	Artificializados	Áreas urbanizadas com infraestruturas e construções que permeabilizam o solo, e também pedreiras ou áreas desflorestadas

- **Classificação não supervisionada**

A classificação não supervisionada envolve o agrupamento de pixels ou de segmentos de imagem com base na sua semelhança espectral, sem conhecimento prévio das classes presentes (Tomar et al, 2022).

Nesta abordagem, inicialmente, foram definidos 10 clusters espectrais para abril, e 15 em julho, utilizando as primeiras e segundas bandas dos principais componentes. Estes números são superiores aos das classes de informação, para contemplar o facto de geralmente existir mais do que uma assinatura espectral em cada classe. Em seguida, os clusters foram reclassificados e agregados nas respetivas classes de informação, conforme definido anteriormente na tabela da nomenclatura. Por fim, é feita a etapa do pós-processamento, através da generalização para reduzir o efeito de ruído típico nas classificações raster.

- **Classificação supervisionada**

A classificação supervisionada envolve o treino de um classificador através da utilização de um conjunto de dados de treino, onde cada amostra é associada a uma classe conhecida (Tomar et al, 2022).

Numa fase inicial, criou-se uma amostra de treino desenhando manualmente e de forma equitativa polígonos para cada classe da tabela 2, tanto para abril (264 polígonos) como para julho (500 polígonos a incluir áreas ardidas).

Posteriormente, geraram-se assinaturas espectrais, das quais se extraíram os números digitais das bandas de cada pixel, para calcular as estatísticas de cada classe de informação. Por via dessa informação, fez-se uma análise da amostra de treino através de um dendrograma.

Por último, para realizar a classificação dos dados de forma mais precisa, aplicou-se o algoritmo de máxima verosimilhança, reclassificou-se a agregação dos clusters e realizou-se a etapa do pós-processamento através da generalização.

3.1.5 Validação

Na etapa de validação dos métodos, foram criados pontos de referência distribuídos pela área de estudo. Estes pontos serviram como base para a construção de matrizes de confusão para ambos os meses analisados, permitindo assim uma avaliação detalhada da exatidão das classificações supervisionada e não supervisionada. Para concluir a análise do trabalho irá realizar-se dois mapas que nos permitem visualmente comparar as áreas ardidas registadas pelo ICNF com os resultados obtidos entre abril e julho pelo classificador supervisionado e classificador não supervisionado.

4 Resultados

4.1 Análise Exploratória

Na análise exploratória, como mencionado anteriormente, foram utilizadas diversas técnicas para compreender e preparar os dados para o desenvolvimento do estudo. Quanto aos compósitos coloridos, nas figuras 3 e 4 estão representadas imagens de cor verdadeira dos meses de abril e julho. Ambas as figuras proporcionam uma visualização realista da área de estudo, com destaque para as áreas ardidas em julho.




Figure 3. Compósito colorido de imagens de cor verdadeira dos mês de abril




Figure 4. Compósito colorido de imagens de cor verdadeira do mês de julho

Os resultados do cálculo do NDVI para ambos os meses, assim como o resultado do dNDVI estão representados na figura 5. Nesta figura, é possível observar a distribuição da vegetação ao longo do Pinhal Interior. É importante destacar que o NDVI foi calculado a partir das bandas 4 (vermelho) e 8 (infravermelho próximo). Em seguida, para calcular o dNDVI, utilizaram-se os dois mapas de NDVI iniciais para obter um mapa que representa a diferença entre o mês de julho e o mês de abril.




Figure 5. Cálculo do dNDVI

Posteriormente, foram calculadas as mudanças na distribuição da vegetação com o dNDVI, utilizando a seguinte fórmula: $\mu - k\sigma < dNDVI < \mu + k\sigma$, originando o mapa final representado na figura 6. Neste mapa, verifica-se que houve uma diminuição da vegetação no Pinhal Interior representada pela cor vermelha, que neste caso deve-se à ocorrência do incêndio. Em contraste, a cor verde observa-se o aumento da cobertura vegetal, enquanto as áreas em cinza indicam a ausência de mudanças significativas.




Figure 6. Mapa de alteração de vegetação do NDVI

No âmbito da análise dos componentes principais, é possível interpretar através da figura 7 que os 4 componentes de abril explicam respetivamente 69,1%, 29,9%, 0,8% e 0,2%, da variabilidade das informações das bandas originais. Enquanto os componentes de julho, representados na figura 8 explicam 63%, 35,8%, 1% e 0,2%, da variabilidade. Destaca-se que os dois primeiros componentes são mais significativos que os restantes em ambos os meses,

explicando juntas 98.99% da variabilidade em abril e 98.83% em julho, sendo estes os únicos utilizados para as classificações.

PERCENT AND ACCUMULATIVE EIGENVALUES			
PC Layer	EigenValue	Percent of EigenValues	Accumulative of EigenValues
1	508717,74247	69,0858	69,0858
2	220167,13922	29,8995	98,9853
3	5826,50409	0,7913	99,7765
4	1645,53925	0,2235	100,0000

Figure 7. Análise dos Componentes principais de abril

PERCENT AND ACCUMULATIVE EIGENVALUES			
PC Layer	EigenValue	Percent of EigenValues	Accumulative of EigenValues
1	725379,82389	63,0343	63,0343
2	411934,40272	35,7964	98,8308
3	11408,38856	0,9914	99,8221
4	2046,78476	0,1779	100,0000

Figure 8. Análise dos componentes principais de julho

4.2 Classificação não supervisionada

Neste ponto foi realizada uma análise utilizando o classificador não supervisionado Isodata Clusters para detetar as áreas florestais afetadas pelos incêndios.

A análise dos mapas de abril e julho, presentes respectivamente nas figuras 9 e 10, mostra poucas alterações nas classes "agricultura" e "áreas artificializadas". As principais mudanças observadas incluem a diminuição da classe "florestas/matos" e o aumento das classes "Ardidos" e "Água".

O aumento da classe "ardidos" combinado com a diminuição de "florestas/matos" comprova a magnitude dos incêndios que ocorreram na região de estudo. Contudo, no mapa de julho, o classificador automático gerou uma confusão espectral entre as classes "água" e "ardidos", indicando erroneamente a presença de água nas áreas afetadas pelos incêndios. As causas subjacentes a este fenómeno serão detalhadas no ponto seguinte.




Figure 9. Mapa de classificação não supervisionada de abril




Figure 10. Classificador não supervisionado de julho

4.3 Classificação supervisionada

Para detetar as transformações ocorridas na cobertura florestal após os incêndios, foi realizada uma análise supervisionada utilizando o classificador de máxima verosimilhança.

Com o intuito de melhorar a precisão na classificação e evitar confusões espectrais, aplicou-se primeiramente o método do dendrograma. Esta ferramenta é útil para compreender as relações espectrais entre diferentes classes de cobertura do solo e avaliar a possível capacidade dos classificadores a distinguir entre elas.

Os dendrogramas fornecidos na figura 11 e 12, representam a estrutura de agrupamento hierárquico das classes para abril e julho, que incluem as seguintes categorias principais: Água (1), Agricultura (2), Florestas/Matos (3), Ardidos (4) e Artificializados (5).

Com o auxílio desta técnica, é possível compreender as diferenças e semelhanças espectrais entre as classes de informação. Na realização do primeiro dendrograma, foi identificada uma grande proximidade espectral entre as classes "floresta" e "matos". Por esse motivo decidiu-se fundir as duas classes numa só, que passou a ser designada como "florestas/matos".

Em ambos os dendrogramas, a classe “água” mantém-se isolada das outras classes, indicando uma assinatura espectral distinta das restantes.

Nos dois períodos, a “agricultura” e “florestas/matos” mostram alta similaridade espectral inicial, agrupando-se em distâncias pequenas, o que sugere que essas classes têm assinaturas espectrais similares devido à vegetação que as caracteriza.

Relativamente à classe “artificializados”, em julho esta classe agrupa-se isoladamente das outras classes, revelando que a sua assinatura espectral é bastante distinta das outras classes. No entanto, em abril, esta diferença não tem tanta expressão.

No dendrograma de julho, a classe “ardidos” agrupa-se com a classe “água”, refletindo uma confusão espectral significativa. Esse agrupamento inesperado indica que as áreas queimadas foram confundidas com os corpos d'água, possivelmente devido a alterações espectrais resultantes dos incêndios.




Figure 11. Dendrograma abril




Figure 12. Dendrograma de julho

Comparando os mapas de abril e julho, observa-se claramente a perda de cobertura florestal devido aos incêndios (figuras 13 e 14).

As áreas da classe “florestas/matos”, que eram em abril predominantemente verdes e cobriam uma vasta área do território, em julho, foram transformadas em áreas castanhas (ardidas), indicando uma perda substancial de vegetação devido aos incêndios.

Isto reflete a extensão dos danos causados pelos incêndios, com grandes porções de vegetação transformadas em áreas queimadas.

As áreas de “agricultura”, representadas a amarelo, estão distribuídas por toda a área de estudo em abril, com maior concentração nas regiões sul e sudoeste. Em julho, a distribuição das áreas agrícolas permanece relativamente constante, indicando que as áreas de cultivo foram menos afetadas pelos incêndios em comparação com as florestas.

A classe da “água”, representada a azul, permanece relativamente constante entre abril e julho, não se tendo feito sentir a confusão espectral observada no “classificador não assistido”.

As áreas “artificializadas”, representadas a vermelho, incluem territórios urbanizados com infraestruturas e construções que impermeabilizam o solo. Nesta análise, essas áreas permaneceram relativamente estáveis entre abril e julho, indicando pouca destruição pelos incêndios.

É importante notar que essa classe apresentou uma certa distorção tanto em abril quanto em julho devido a um erro de classificação do classificador. Durante o treino de amostragem, as áreas desflorestadas foram atribuídas à classe “florestas/matos”, mas o classificador não conseguiu distingui-las corretamente, classificando-as como áreas artificializadas e, ocasionalmente, como “agricultura”. Este ponto será abordado na discussão.

A expressividade destas áreas desflorestadas ainda é significativa na área de estudo em causa, porque uma das espécies predominantes é o eucalipto, e a sua produção e colheita ocorre em ciclos curtos devido à forte procura, para posterior utilização na indústria do papel, (Assembleia da República, 2018, p.243).




Figure 13. Imagem classificada com o classificador supervisionado de máxima verossimilhança de abril




Figure 14. Imagem classificada com o classificador supervisionado de máxima verossimilhança de julho

5 Validação

No processo de validação, geraram-se 135 pontos aleatórios utilizando a ferramenta ArcGIS Random Points, os quais foram etiquetados de acordo com a classificação mencionada anteriormente. Observou-se que as “florestas/matos” estavam significativamente sobre-representadas com 110 dos 135 pontos (81,5%) em abril, enquanto julho apresentou uma distribuição mais equilibrada. Esta sobre-representação justifica-se pela sua presença predominante na região do Pinhal interior. Em contrapartida, não foram considerados pontos de “água”, e tanto a “agricultura” como a classe “artificializados” encontravam-se bastante subamostrados. Embora o objetivo não fosse obter uma representação igual, é importante incluir mais pontos nessas classes, para garantir uma validação mais precisa e abrangente.

Como era de se esperar, os classificadores supervisionados tiveram uma melhor performance, embora para abril a diferença seja marginal, de 2%. Entrando nos detalhes das classificações, a avaliação da performance dos classificadores torna-se muito menos evidente com as seguintes observações:

- ❖ A “água” é a classe com a melhor performance de classificação, exceto para a classificação não supervisionada de julho, onde as estimativas do classificador estavam corretas com uma taxa de 43%, tendo 12 dos 21 pontos classificados como “água”, quando deveriam corresponder a pixels ardidos no conjunto de dados da validação. Isto reflete bem um fenómeno observado durante a classificação não supervisionada de julho onde o classificador confundia sistematicamente “áreas ardidas” com a “água”.
- ❖ No que diz respeito à classificação das áreas ardidas, o foco principal do trabalho:
 - O classificador supervisionado teve uma melhor performance conseguindo identificar corretamente os pontos de validação ardidos com uma taxa de sucesso de 83%, contra os 70% da classificação não supervisionada. Os respetivos erros de omissão são então de 17% e 30%, sendo que para a classificação não supervisionada os pontos ardidos foram confundidos com “florestas/matos” e “água”, enquanto na classificação supervisionada a omissão foi causada por confusão com “agricultura” e florestas.
 - Do ponto de vista da fiabilidade da classificação, 95% dos pontos classificados como ardidos eram efetivamente ardidos para a classificação supervisionada, enquanto a classificação não supervisionada demonstrou-se ser menos fiável: só 69% dos pixels classificados como ardidos o eram efetivamente. Neste último caso, os pixels classificados como ardidos eram, na verdade, “agricultura” e “florestas/matos”.

O desempenho global da classificação não supervisionada de abril foi de 85% de exatidão, enquanto a supervisionada foi de 87%. Sendo que a classificação não supervisionada requer menos trabalho por não necessitar a criação de uma camada de treino, à primeira vista pode parecer que com uma melhor exatidão global seja a mais adequada para este trabalho. Nota-se, porém, que:

- ❖ Pontos de validação ligados à “água” como cobertura do solo foram identificados corretamente com uma taxa de 90% com os dois métodos de classificação;
- ❖ O classificador supervisionado teve mais sucesso em identificar pontos ligados à “agricultura”, acertando 73% do tempo (60% de acertos para o não supervisionado);

- ❖ O classificador não supervisionado teve melhor desempenho na identificação dos pontos identificados como “floresta” acertando 95% das vezes (88% de acertos para a classificação supervisionada). Do ponto de vista da fiabilidade da classificação, 95% dos pixéis classificados de forma supervisionada como floresta acabaram por sê-lo, enquanto esta taxa é de 90% para a classificação não supervisionada. Assim, na identificação de “florestas/matos” o classificador não supervisionado teve a melhor prestação com o conjunto de dados da validação, mas as suas classificações mostraram ser menos fiáveis. A escolha fica difícil perante esta situação complexa. Poderia prever-se uma segunda validação centrada nas florestas para resultados mais conclusivos. Isto seria particularmente importante para concelhos que não têm uma cartografia atualizada das suas zonas florestais, que são as mais vulneráveis aos incêndios.

Table 3. Matrizes de confusão dos classificadores

Abril supervisionado (EG: 85%)							
	água	agri.	flor.	ardi.	arti.	total class.	UA
água	9					10	100%
agricultura	1	22	8		4	19	63%
florestas/matos		5	97			115	95%
ardidos							
artificializados		3	5		14	24	64%
total validação	10	30	110		18	168	
PA	90%	73%	88%		78%		
Abril não supervisionado (EG: 87%)							
água	9		1			10	90%
agricultura		18	1			19	95%
florestas/matos		8	104		3	115	90%
ardidos							
artificializados	1	4	4		15	24	63%
total validação	10	30	110		18	168	
PA	90%	60%	95%		83%		
Julho supervisionado (EG: 78%)							
água	9					9	100%
agricultura		24	10	3	9	46	52%
florestas/matos		4	50	5		59	85%
ardidos			2	39		41	95%
artificializados	1	1	2		9	13	69%
total validação	10	29	64	47	18	168	
PA	90%	83%	78%	83%	50%		
Julho não supervisionado (EG: 69%)							
água	9			12		21	43%
agricultura	1	22	6		8	37	59%
florestas/matos		4	43	2	1	50	86%
ardidos		2	13	33		48	69%
artificializados		1	2		9	12	75%
total validação	10	29	64	47	18	168	
PA	90%	76%	67%	70%	50%		

Os mapas das figuras 15 e 16, permitem-nos comparar as áreas ardidas registadas pelo ICNF e os resultados das áreas ardidas, entre abril e julho, apurados respetivamente, pelo classificador supervisionado e pelo classificador não supervisionado.

A classe “território ardidos” a castanho, refere todas as combinações de classes de informação designadas na nomenclatura que se transformaram em áreas ardidas.

A conclusão a que chegamos é que a performance do classificador assitido mostra um resultado satisfatório e mais aproximado com os dados registados do ICNF, ao contrário do classificador não supervisionado, que como já explicado anteriormente, teve confusões espereais entre a classe da “água” e a classe “ardidos”, que lhe confere uma menor exatidão de análise (designados como “outras alterações a laranja”).




Figure 15. Comparação entre as áreas ardidas do ICNF e os resultados obtidos com a classificação supervisionada entre abril e julho




Figure 16. Comparação entre as áreas ardidas do ICNF e os resultados obtidos com a classificação não supervisionada entre abril e julho

6 Discussão

Tendo em conta os resultados apresentados, realizaram-se mais pesquisas que permitiram compreender melhor e perceber o que poderia ser melhorado nesta metodologia. Como tal, nesta secção serão partilhadas sugestões de melhoria futura:

Bastarrika et al. publicaram em 2011 um estudo seminal sobre a identificação de áreas ardidas intitulado "*Mapping burned areas from Landsat TM/ETM+ data with a two-phase algorithm: Balancing omission and commission errors*", que inclusivamente foi validado com dados de áreas em Portugal.

No seu algoritmo, utilizaram bandas na gama do visível, bem como infravermelhos próximos e infravermelhos de ondas curtas (1 e 2). As bandas na gama do visível foram utilizadas principalmente para identificar a vegetação. O infravermelho próximo e o infravermelho de ondas curtas (SWIR, 1,5-1,8 μm) permitiram melhorar a discriminação das áreas ardidas, o que já teria sido feito através da análise da vegetação. Os índices com a 2ª banda SWIR (entre 2 e 2,2 μm) ofereceram uma identificação mais exata das áreas ardidas. A combinação dos seguintes índices utilizados nesta abordagem permitiu minimizar os erros de comissão (pixéis identificados como ardidos, mas que não o estavam) e os erros de omissão (pixéis que estavam ardidos, mas que não foram identificados como tal):

- ❖ NDVI (Normalized Difference Vegetation Index)
- ❖ GEMI (Global Environmental Monitoring Index)
- ❖ BAI (Burned Area Index)
- ❖ NBRS (Normalized Burn Ratio)
- ❖ BAIMS (Burned Area Index)

- ❖ NBRL (Normalized Burn Ratio)
- ❖ BAIML (Burned Area Index)
- ❖ MIRBI (Mid Infrared Burn Index)

(Bastarrika et al., 2011).

Esta metodologia mostra que poderíamos ter enriquecido a informação fornecida aos nossos classificadores poderia ter sido enriquecida utilizando outras bandas e índices como os acima mencionados.

Durante a análise realizada, uma questão significativa que surgiu foi a variedade de categorias de ocupação do solo e as suas diferentes expressões. A abordagem adotada foi predominantemente temática, explorou-se a região do Pinhal Interior e identificaram-se as classes consideradas relevantes. Contudo, reconheceu-se que poderia ter sido mais exaustiva a criação das classes, pesquisando na paisagem todas as expressões das mesmas. Um exemplo bem-sucedido foi a fusão que se realizou entre as florestas e os matos. Ao classificá-los inicialmente em separado, conseguimos avaliar melhor o desempenho da nossa classificação, mesmo que depois se acabasse a fundi-los, porque, por um lado, havia muita confusão entre os dois e, por outro, não era tão relevante para o estudo fazer essa distinção, uma vez que estamos à procura de uma metodologia que não tem de ser exaustivamente detalhada nas coberturas do solo antes do incêndio.

Também se utilizou a COS2018 como dado auxiliar para ajudar a criar o conjunto de dados de treino e o conjunto de dados de validação. Durante o treino de amostragem, foram identificadas áreas desflorestadas às quais se atribuiu a classe “florestas/matos”, mas o classificador considerou-as como áreas artificializadas e, ocasionalmente, como “agricultura”. À posteriori, percebeu-se que uma classe para solo descoberto teria sido benéfica, pois adicionar essas áreas às classes que correspondem ao seu uso do solo (em vez de cobertura), acabou por afetar a eficácia dos classificadores no agrupamento dessas áreas.

Assim, de futuro, seria recomendado adotar numa metodologia de criação de áreas de treino e de validação mais robustas que:

- Adote a abordagem de amostragem aleatória estratificada em vez de uma abordagem puramente aleatória (para a amostragem dos dados de validação), em que a população é dividida em subgrupos não sobrepostos e são retiradas amostras aleatórias de cada grupo. Deste modo, evitava-se o trabalho de correção da amostragem aleatória através da amostragem manual, como se realizou (García-Álvarez et al., 2022);
- Incluir uma fase exploratória mais minuciosa com uma listagem exaustiva de todas as coberturas do solo que são vistas, de modo a determinar as melhores coberturas do solo para a classificação, mesmo que estas acabem por não ser as coberturas do solo finais dos resultados;
- Incorporar um mecanismo de verificação para garantir que os diferentes amostradores têm o mesmo entendimento da área e do que vêem, pois por várias vezes pouco era o entendimento da ocupação do solo associada a um ponto de validação. Notou-se isto na fase de validação, o que significa que pode ter afetado os dados de treino. Um exemplo de um mecanismo seria dois amostradores classificarem a mesma área, identificarem as áreas em que há desacordo e discutir-se o assunto em conjunto.

7 Conclusão

Este estudo proporciona uma visão abrangente sobre a eficácia e as limitações do classificador supervisionado de máxima verosimilhança e do classificador não supervisionado Isodata Clustering na identificação de áreas ardidas, especialmente após os devastadores incêndios de 2017 na região do Pinhal Interior.

Os resultados revelaram que os classificadores supervisionados apresentaram uma ligeira vantagem de desempenho em comparação com os classificadores não supervisionados, devido à sua maior fiabilidade. No entanto, em situações de crise, a classificação não supervisionada destaca-se pela implementação mais rápida e pela ausência da necessidade de um conjunto de dados de treino.

Entretanto, a análise das classificações revelou desafios significativos em ambas as abordagens. A confusão entre classes destaca a necessidade de aprimoramento dos inputs para que os classificadores possam produzir os melhores resultados possíveis. Além disso, a disparidade na representação das classes de cobertura do solo evidencia a importância de uma amostragem mais equilibrada para uma validação precisa e abrangente.

Em suma, este estudo enfatiza o potencial da utilização de classificadores para a identificação precisa das áreas ardidas, especialmente em regiões propensas à ocorrência de incêndios.

8 Bibliografia

- Assembleia da República (2018). *Avaliação dos incêndios ocorridos entre 14 e 16 de outubro de 2017 em Portugal Continental*. Relatório final, 1-320. Instituto Nacional de Estatística (2015). As novas unidades territoriais para fins estatísticos, 1-32.
- Bastarrika, Aitor & Chuvieco, Emilio & Martín, **Maria**. (2011). *Mapping burned areas from Landsat TM/ETM+ data with a two-phase algorithm: Balancing omission and commission errors*. Remote Sensing of Environment. 115. 1003-1012. 10.1016/j.rse.2010.12.005.
- Caetano, M. and Costa, H., 2023. *Remote sensing practicals*, [e-book]. NOVA Information Management School, Universidade Nova de Lisboa.
- Castro, A., & Amaral, A. (2017). *Normalized Difference Vegetation Index (NDVI) for evaluation of forest fires in the summer of 2016 in Portugal*. Mestrado em Engenharia Geográfica, Departamento de Geociências, Ambiente e Ordenamento do Território.
- García Álvarez, David & Camacho Olmedo, María Teresa & Paegelow, Martin & Mas, Jean. (2022). *Land Use Cover Datasets and Validation Tools. Validation Practices with QGIS*. 10.1007/978-3-030-90998-7.
- Tomar, R. S. et al. (Eds.). (2022). *Communication, Networks and Computing: Third International Conference, CNC 2022, Gwalior, India, December 8–10, 2022, Proceedings, Part I*. (Communications in Computer and Information Science Series). Springer.